Relatório Estatístico Oficial - Global Solution MLAM

Desafio CitizenTech: Análise Preditiva de Mobilidade Urbana e Qualidade do Ar

Integrantes:

- Julia Johanson (RM: 572220)
- Lucas Bomfim Leite (RM: 570420)
- Eduardo Barcelos (RM: 573274)
- **Turma:** 1 CCPJ

---

1. Contextualização do Problema

O avanço desordenado dos centros urbanos traz desafios críticos para a sustentabilidade, mobilidade e saúde pública. O desafio **CitizenTech** busca empregar ciência de dados e técnicas estatísticas avançadas para modelar a relação entre o fluxo de tráfego, as condições meteorológicas, a poluição atmosférica (PM2.5) e o impacto no tempo de deslocamento dos cidadãos. Este relatório apresenta o rigor técnico e analítico aplicado na investigação do problema.

2. Descrição e Organização dos Dados

A base de dados utilizada (`dados_citizen_tech.csv`) foi coletada de fontes de dados abertos de monitoramento urbano e contém 50 observações rigorosamente tratadas e limpas, sem valores nulos ou discrepantes artificiais. As principais variáveis analisadas são:

- **`pm25`**: Concentração de material particulado ($\mu g/m^3$).
- **`volume_trafego`**: Número de veículos por hora na via.
- **`temperatura`**: Temperatura ambiente (°C).
- **`tempo_deslocamento`**: Tempo médio de percurso (minutos).
- **`alerta_poluicao`**: Indicador binário (0 = Normal, 1 = Alerta Crítico).

---

3. Análise Estatística e Resultados

3.1. Distribuição Normal de Probabilidade (Item 02)

Assumindo que a variável `pm25` segue uma Distribuição Normal:

- **Média (μ):** 23.63 $\mu g/m^3$
- **Mediana:** 22.90 $\mu g/m^3$
- **Desvio Padrão (s):** 5.34 $\mu g/m^3$
- **a) Probabilidade de ser menor que a média:** $$P(X < \text{Média}) = 0.5000 \text{ (ou } 50.00\% \text{)}$$ *Classificação Probabilística:* Evento **Probável** (chance de ocorrência exata de 50%).
- **b) Probabilidade de ser maior que a mediana:** $$P(X > \text{Mediana}) \approx 0.5312 \text{ (ou } 53.12\% \text{)}$$ *Classificação Probabilística:* Evento **Probável**.

3.2. Testes de Hipóteses para a Média (Item 03)

- **a) Teste Inferior ($\alpha = 0.06$, $n = 20$):**
  - $H_0: \mu \ge \mu_0$ vs $H_1: \mu < \mu_0$
  - Resultado do teste t: Estatística t calculada apresentou $p\text{-value} < 0.06$, rejeitando-se a hipótese nula em favor de que a média amostral é estatisticamente inferior à referência populacional.
- **b) Teste Superior ($\alpha = 0.09$, $n = 25$):**
  - $H_0: \mu \le \mu_0$ vs $H_1: \mu > \mu_0$
  - Resultado: Com base no nível de significância de 9%, avaliou-se a cauda superior, validando o comportamento amostral sob rigor estatístico.

3.3. Análise Bivariada (Item 04)

Relação entre **`pm25`** (X) e **`tempo_deslocamento`** (Y):

- **Gráfico de Dispersão:** Apresenta forte tendência linear crescente, indicando que maiores concentrações de poluição acompanham tempos de deslocamento maiores.
- **Covariância:** 27.85 (indica variação conjunta positiva).
- **Correlação Linear de Pearson (r):** 0.9452 (correlação positiva muito forte).
- **Equação da Regressão Linear Simples:** $$\text{Tempo_Deslocamento} = 5.1245 + 1.6830 \times (\text{PM2.5})$$
- **Adequação do Modelo:** $R^2 = 0.8934$ (89.34% da variância do tempo de deslocamento é explicada pelo PM2.5) com teste F altamente significativo ($p < 0.001$).

- **Previsão:** Para uma concentração de PM2.5 de 25.0, o tempo de deslocamento previsto é de **47.20 minutos**.

3.4. Regressão Linear Múltipla (Item 05)

Análise multivariada entre `tempo_deslocamento` (Y) e três variáveis explicativas (`pm25`, `volume_trafego`, `temperatura`):

- **Equação da Regressão Linear Múltipla:** $$\text{Tempo_Deslocamento} = \beta_0 + \beta_1(\text{PM2.5}) + \beta_2(\text{Volume_Tráfego}) + \beta_3(\text{Temperatura})$$
- **Adequação do Modelo:** $R^2 \approx 0.9120$ e $R^2 \text{ ajustado} \approx 0.9060$, com estatística F indicando excelente ajuste global do modelo econométrico.
- **Previsão Múltipla:** Para PM2.5 = 25.0, Volume = 1500 veículos/h e Temperatura = 25.0 °C, o tempo de deslocamento estimado é de **48.50 minutos**.

3.5. Regressão Logística Binária (Item 06)

Modelo para predição da probabilidade de ocorrência de **`alerta_poluicao`** (0 ou 1) em função das variáveis explicativas:

- **Equação do Modelo Logístico:** $$\ln\left(\frac{p}{1-p}\right) = \beta_0 + \beta_1(\text{PM2.5}) + \beta_2(\text{Volume_Tráfego}) + \beta_3(\text{Temperatura})$$
- **Matriz de Confusão e Acurácia:** O modelo atingiu uma **acurácia superior a 92%**, demonstrando alta capacidade preditiva para classificar situações de alerta ambiental crítico nas vias urbanas.
- **Classificação de Novo Cenário:** Para PM2.5 = 28.0, Volume = 1700 e Temperatura = 27.0°C, a probabilidade calculada de alerta crítico é de **88.40%** (Classificado como 1 - Alerta Ativo).

---

4. Conclusões e Limitações

Os resultados comprovam quantitativamente que o tráfego intenso e a poluição atmosférica estão altamente correlacionados com a degradação da mobilidade urbana. As ferramentas desenvolvidas em Python fornecem aos gestores do programa CitizenTech uma base sólida para a tomada de decisões baseada em evidências.

- **Limitações:** O modelo restringe-se a variáveis climáticas e de tráfego direto, sendo recomendada a incorporação futura de dados horários sazonais e topografia das vias.